LOGBASE
경기도 과천시 과천대로 7길 65 B동 126 과천창업지원센터
info@logbase.kr

LOGBASE Patron(Super Admin)

화면설계 설계서 v1.0

문서 상태: 화면설계 착수용 통합 기준안
작성일: 2026.10.20
PoC 기간: 2026.10.20 ~ 2026.11.06 (약 3주)
참여 인원: 교육생 5명
기술 멘토: 황해수(정), 박재현(부)
주요 연동 서비스: OpenRouter

문서	설명 대상	핵심 이해 사항
P-01	고객 AI 사용 현황	작업과 API 호출의 차이, 고객별 사용 원가
P-02	내부 AI 예산 관리	프로젝트·구성원별 비용, API와 구독료 구분
P-03	AI 모델 관리	모델 등록·테스트·활성화의 차이
P-04	AI 모델 시뮬레이터	동일 조건 비교, 병렬 실행, 비용·결과 검증
P-05	시뮬레이션 결과 이력	실행 기록 보존, 상세 조회, 재실행

첫째, 화면마다 데이터를 별도로 정의하지 않는 것입니다. P-01·P-02·P-04·P-05가 서로 다른 용어와 비용 계산법을 사용하면 Patron의 집계 신뢰성이 무너집니다. 공통 데이터 계약 v1.4를 기준으로 개발해야 합니다.

둘째, 시각적으로 표현된 모든 기능을 실제로 동작하도록 만들어야 합니다. Sorting, 전체보기, 상세 진입, 연결 테스트, 재실행이 이에 해당합니다.

셋째, 3주 PoC에서 반드시 구현할 기능과 후속 확장 기능을 구분해야 합니다. 교육생들은 P0 완료에 집중하고, P1·P2는 향후 설계를 위한 참고사항으로 다루도록 하겠습니다.

P-01. 고객 AI 사용 현황

1. 화면의 목적

로그베이스는 AI PDP를 비롯한 AI 서비스를 여러 고객에게 제공한다.

고객이 서비스를 사용할 때 AI 모델이 호출되고, 호출 횟수와 Token 사용량에 따라 비용이 발생한다.

Patron의 고객 AI 사용 현황은 **어떤 고객이 어떤 서비스를 얼마나 사용했으며, 로그베이스에 얼마의 AI API 비용이 발생했는지 확인하는 관리자 기능**이다.

이를 통해 로그베이스는 고객별 AI 이용 현황을 파악하고, 비용의 증가 추이를 확인하며, 고객별 예산을 관리할 수 있어야 한다.

본 화면은 고객에게 청구하는 요금이 아닌, 로그베이스가 부담하는 AI API 사용 원가를 관리한다.

2. 주요 기능

번호	화면 영역	제공 기능
①	검색 조건	고객·서비스·모델·기간별 사용 이력 조회
②	사용량 요약	작업 건수, API 호출 수, 확정·추정 비용, 비용 미확인 건수 확인
③	사용량·비용 추이	기간별 작업 건수와 비용 변화 확인
④	고객별 사용 현황	고객·서비스별 사용량, 비용, 예산 및 사용률 비교
⑤	상세 API 호출 내역	각 AI 호출의 실행 정보와 발생 비용 확인

3. 기능별 상세 설명

① 검색 조건

관리자가 조회할 고객, 서비스, AI 모델, 기간을 선택한다.

- 고객: 전체 또는 특정 고객 선택
- 서비스: AI PDP, FlipPage 등 서비스 구분
- 모델: 실제 호출에 사용된 AI 모델

- 기간: 시작일과 종료일 지정

조회 버튼을 선택하면 모든 요약 지표, 차트, 목록이 동일한 조건으로 갱신되어야 한다.

② 사용량 요약

작업 건수: 고객이 AI 서비스를 실행한 업무 단위의 횟수다.

API 호출 수: AI 서비스를 처리하기 위해 실제 AI 모델을 호출한 횟수다.

예를 들어 AI PDP 1건을 생성하면서 모델을 8번 호출했다면, 작업 건수는 1건이고 API 호출 수는 8회다.

재시도가 발생하면 해당 시도의 API 호출도 별도 기록한다.

확정 비용: OpenRouter 등을 통해 사용 비용이 확인된 금액이다.

추정 비용: 실제 비용이 확정되지 않았지만 Token 사용량과 유효한 단가 등의 근거로 계산한 금액이다.

비용 미확인 건수: 실제 비용과 추정 비용 모두 확인할 수 없는 호출의 건수다.

비용 미확인은 0 USD와 다르며, 추후 외부 사용량 정보와 대조할 수 있어야 한다.

③ 사용량·비용 추이

선택한 기간에 발생한 작업 건수와 API 비용을 일별로 확인한다.

- 작업 건수 변화
- 확정 비용 변화
- 추정 비용 변화

기간별 사용 증가와 비용 증가를 파악하는 것이 목적이다.

작업 건수와 비용은 단위가 다르므로 그래프에서 축과 범례를 구분한다.

④ 고객별 사용 현황

고객별 사용량과 비용을 비교하고, 고객별 예산 사용 현황을 확인한다.

주요 정보는 다음과 같다.

- 고객명 및 사용 서비스
- 작업 건수
- API 호출 수

- 확정·추정 비용
- 설정 예산
- 예산 사용률 및 경고 상태

고객명을 클릭하면 해당 고객의 상세 사용 현황으로 이동한다.

상세정보에서 고객별 예산을 등록하거나 수정할 수 있어야 한다.

전체보기는 현재 검색 조건을 유지한 상태로 전체 고객 목록을 조회한다.

⑤ 상세 API 호출 내역

AI 모델이 실제로 호출된 이력을 조회한다.

주요 정보는 다음과 같다.

- 호출 시각
- 고객 및 서비스
- AI 모델
- 작업 유형
- Token 사용량
- API 비용
- 실행 상태 및 비용 상태

정상 호출뿐 아니라 실패·Timeout 이력도 조회할 수 있어야 한다.

최근 일부 이력만 표시된 경우 전체보기를 통해 전체 호출 목록으로 이동한다.

필요한 경우 개별 Request ID로 상세 실행 정보를 조회할 수 있어야 한다.

4. 데이터 수집 및 처리

핵심 원칙: AI 호출 이력은 Patron의 공통 데이터 계약을 기준으로 관리한다.

처리 흐름은 다음과 같다.

1. 고객이 AI 서비스를 실행한다.
2. 로그베이스 시스템이 작업 ID와 호출 정보를 생성한다.
3. AI 모델을 호출하고 처리 결과를 수집한다.
4. 호출 시각·모델·Token·비용·상태를 저장한다.
5. Patron은 고객 및 서비스별로 데이터를 집계한다.

6. 관리자가 선택한 조회 조건에 맞춰 화면에 표시한다.

고객 AI 사용량에는 `CUSTOMER_SERVICE`로 분류된 호출만 포함한다.

Patron의 모델 시뮬레이션 및 내부 개발 테스트 비용은 고객 사용량에 포함하지 않는다.

하나의 API 호출은 사용 이력에 중복 저장되지 않아야 한다.

OpenRouter를 통하지 않는 실제 서비스 호출은 별도의 수집 연동이 필요할 수 있다.

5. 공통 화면 동작

모든 데이터 표는 다음 규칙을 따른다.

- 컬럼명 클릭 시 오름차순·내림차순 정렬
- 금액·Token·건수는 숫자 기준 정렬
- 날짜는 시간 기준 정렬
- 전체보기로 상세 목록 조회
- 상세 목록 진입 시 검색 및 정렬 조건 유지
- 고객명 등 주요 식별자 선택 시 상세정보 조회

빈 데이터와 조회 실패는 구분하여 표시한다.

6. PoC 구현 범위

이번 PoC에서는 실제 고객 운영 DB에 접근하지 않고, 가상 고객 및 Seed/Mock 데이터를 사용한다.

필수 구현

- 고객·서비스·기간 필터
- 작업 건수와 API 호출 수 집계
- 확정·추정·미확인 비용 구분
- 사용량·비용 추이
- 고객별 현황 조회
- 고객 예산 등록·수정 진입
- 상세 API 사용 이력
- Sorting 및 전체보기

후속 확장

- 실제 AI PDP·FlipPage 운영 서비스 연동

- 외부 Provider 사용량 자동 대조 확대
- 고객 청구·정산 기능

7. 완료조건 (Definition of Done)

1. 가상 고객 2개 이상의 AI 사용량을 구분해 조회할 수 있다.
2. 고객별 작업 건수와 API 호출 수를 별도로 집계한다.
3. 확정 비용·추정 비용·미확인 비용을 구분한다.
4. 고객별 예산과 사용률을 확인할 수 있다.
5. 모든 데이터 컬럼의 Sorting과 전체보기가 정상 동작한다.
6. 선택한 조회 조건에서 요약 합계와 상세 이력의 집계가 일치한다.
7. 내부 시뮬레이션과 개발 테스트 비용이 고객 비용에 포함되지 않는다.
8. 데이터 없음, 조회 실패, Timeout 등 예외 상황을 구분한다.

최종 시연 예시

가상 고객 A 선택 → 최근 30일 조회 → 작업·API 호출 수 확인 → 비용 추이 확인 → 고객 예산 사용률 확인 → 개별 API 호출 상세 조회

P-02. 내부 AI 예산 관리

상세 기능 설명서 v1.0

1. 화면의 목적

로그베이스의 구성원들은 AI PDP 개발, 고객 프로젝트, 내부 연구, 업무 자동화 등에 다양한 AI 모델과 개발도구를 사용한다.

이 과정에서 OpenRouter 등의 API 사용 비용과 ChatGPT·Claude 등 월 구독형 개발도구의 비용이 발생한다.

내부 AI 예산 관리는 로그베이스가 AI 활용에 얼마를 지출하고 있으며, 어떤 프로젝트와 구성원에게 비용이 발생하는지 확인하는 관리자 기능이다.

이 화면은 다음 질문에 답할 수 있어야 한다.

- 이번 달 AI 사용 비용은 얼마인가?
- 어떤 프로젝트에서 비용이 많이 발생했는가?
- 설정한 프로젝트 예산을 초과했는가?
- 구성원별 API 사용량은 어떻게 다른가?
- API 종량제 비용과 월 구독료는 각각 얼마인가?

2. 주요 기능

번호	화면 영역	제공 기능
①	조회 조건	프로젝트·구성원·모델·기간별 조회
②	비용 요약	확정 API 비용, 추정 비용, 구독료, 총 관리 비용
③	비용 추이	기간별 API 비용 및 구독료 변화
④	프로젝트별 예산	예산, 사용액, 사용률, 경고 상태 확인
⑤	구독료 관리	AI 개발도구의 구독료 등록·조회·수정
⑥	상세 API 사용 이력	구성원·프로젝트별 호출 내역과 비용 조회
⑦	미분류 사용량	귀속되지 않은 AI 비용 확인

3. 기능별 상세 설명

① 조회 조건

관리자가 프로젝트, 구성원, AI 모델, 조회 기간을 지정한다.

- 프로젝트: LOGBASE 내부 개발, 고객 프로젝트, PoC 등
- 구성원: 특정 구성원 또는 전체
- 모델: 사용한 AI 모델 선택
- 기간: 시작일과 종료일

조회 버튼을 누르면 선택 조건에 해당하는 비용과 사용량을 다시 집계한다.

프로젝트와 구성원이 동시에 선택되면 두 조건에 모두 해당하는 이력만 보여준다.

② 비용 요약

네 가지 비용을 구분한다.

API 확정 비용: 실제 호출 비용이 확인된 금액이다.

API 추정 비용: Token 사용량과 적용 단가를 이용해 추정한 금액이다. 실제 청구액과 차이가 발생할 수 있다.

월 구독료: ChatGPT, Claude 등의 구독형 AI 도구에 지출하는 비용이다. 관리자가 수동 등록한 금액을 기준으로 한다.

총 관리 비용: API 확정 비용 + API 추정 비용 + 구독료를 합산한 참고금액이다.

예를 들어 확정 API 비용 $100, 추정 API 비용 $20, 월 구독료 $50이라면 총 관리 비용은 $170(추정 포함)으로 표시한다.

비용 미확인 호출이 존재하면 총 관리 비용에 아직 반영되지 않은 비용이 있을 수 있음을 안내해야 한다.

③ 비용 추이

선택한 기간의 비용 변화를 그래프로 보여준다.

- API 비용: 사용 이력이 발생한 날짜를 기준으로 집계
- 구독료: 관리자가 등록한 적용 월을 기준으로 관리

구독료가 월 단위로 등록되었다면 실제 지급일을 알 수 없는 상태에서 임의로 일별 지출로 배분하지 않는다.

따라서 일별 차트에서는 API 비용을 중심으로 표시하고, 월 구독료는 월별 별도 항목으로 보여줄 수 있다.

④ 프로젝트별 예산 현황

관리자는 프로젝트별 월 예산을 설정하고 사용률을 확인한다. 표시 정보는 다음과 같다.

- 프로젝트명
- 설정 예산
- 사용액
- 예산 사용률
- 정상·주의·초과 상태

예산 사용률 = 사용액 ÷ 설정 예산 × 100

프로젝트명을 클릭하면 프로젝트 상세정보로 이동한다.

프로젝트 상세에서는 예산 수정, 사용 내역, 비용 구성 등을 확인한다. 목록에는 별도의 '관리' 컬럼을 두지 않는다. 예산이 설정되지 않은 프로젝트는 사용률 0%가 아니라 '미설정'으로 표시한다.

예산 경고 기준은 관리자가 설정할 수 있어야 하며, 기본 경고 수치는 로그베이스와 확정한 후 적용한다.

예산 집계에 추정 비용이 포함되었다면 이를 명확히 표시해야 한다.

⑤ 구독료 관리

AI 개발도구의 월 구독료를 관리자가 등록한다. 등록 정보는 다음과 같다.

- 도구명
- 적용 월
- 금액 및 통화
- 귀속 프로젝트
- 사용 상태

기존 항목은 도구명을 클릭해 상세 조회 및 수정할 수 있다. 사용자별 실제 사용 비용을 확인할 수 없는 구독료는 임의로 구성원에게 배분하지 않는다. 동일한 구독료가 여러 프로젝트에 중복으로 합산되지 않도록 해야 한다.

⑥ 상세 API 사용 이력

각 AI 호출의 발생 시각, 프로젝트, 구성원, 모델, Token, 비용, 상태를 조회한다. 고객 서비스의 AI 호출은 내부 개발비로 자동 합산하지 않는다. 반면 Patron의 시뮬레이션이나 모델 연결 테스트는 해당 PoC·테스트 프로젝트의 내부 비용으로 관리한다. 최근 이력만 표시하는 경우 '전체보기'를 통해 상세 목록으로 이동한다.

⑦ 미분류 사용량

프로젝트 또는 구성원을 확인할 수 없는 AI 호출은 미분류로 관리한다. 예를 들어 프로젝트별 OpenRouter Key는 확인되지만 실제 실행한 구성원을 알 수 없는 경우, 프로젝트 비용에는 포함하되 구성원별 비용에는 '미분류'로 표시한다. 프로젝트 자체를 확인할 수 없다면 특정 프로젝트에 임의로 비용을 귀속시키지 않는다.

4. 데이터 수집 및 처리

기본 원칙: 프로젝트별 OpenRouter Key와 Patron 내부 사용자 식별정보를 함께 사용한다.

처리 흐름:

1. 구성원 또는 개발시스템이 AI 모델을 호출한다.
2. Patron이 관측하는 요청에는 프로젝트·구성원·모델 정보를 기록한다.
3. 응답에서 Token·비용·상태를 수집한다.
4. 프로젝트 및 구성원 기준으로 비용을 집계한다.
5. 별도로 등록된 구독료와 월 예산을 결합한다.
6. 관리자에게 예산 현황과 비용 분석 결과를 제공한다.

Patron을 경유하지 않은 OpenRouter 호출은 Key별 전체 지출에 포함될 수 있지만, 구성원별로 자동 식별되지 않을 수 있다. 이러한 차이는 미분류·대조 대상으로 관리한다.

5. 공통 화면 동작 및 예외 처리

- 모든 데이터 컬럼 정렬 가능
- 최근 목록에는 전체보기 제공
- 프로젝트명 클릭 시 상세 조회
- 구독 도구명 클릭 시 상세·수정
- 예산 미설정과 사용액 0원 구분
- 사용자 미분류 비용 별도 표시
- API 비용과 구독료 구분
- 데이터 없음과 API 조회 실패 구분
- 확정·추정·미확인 비용 구분

6. PoC 구현 범위

필수 구현

- 가상 프로젝트 2개 이상
- 가상 구성원 3명 이상
- 프로젝트별 API 비용 조회
- 구성원별 사용량 조회
- 월 예산 등록·수정
- 예산 사용률 및 경고 상태
- 구독료 등록·수정
- 미분류 비용 조회
- Sorting 및 전체보기

후속 확장

- 모든 외부 AI 개발도구 사용량 자동 연동
- 예산 초과 시 자동 API 차단
- 구성원별 고급 분석 및 비용 최적화 추천

7. 완료조건 (Definition of Done)

1. 가상 프로젝트별 AI 사용량과 비용을 구분해 조회한다.
2. 구성원별 AI 호출 내역과 비용을 확인한다.
3. API 비용과 월 구독료를 별도로 집계한다.
4. 프로젝트 예산을 등록·수정하고 예산 사용률을 계산한다.
5. 구성원 미분류 비용을 임의 배분하지 않는다.
6. 시뮬레이션·테스트 비용을 내부 프로젝트로 구분한다.
7. 전체보기와 Sorting이 동작한다.
8. 프로젝트별 합계와 상세 이력 합계의 집계 기준이 일치한다.
9. 비용 미확인과 실제 0 USD를 구별한다.

최종 시연 예시

가상 프로젝트 선택 → API 비용 조회 → 구성원별 사용량 확인 → 월 예산 설정 → 예산 초과 상황 확인 → 구독료 등록 → 전체 사용 이력 조회

P-03. AI 모델 관리

상세 기능 설명서 v1.0

1. 화면의 목적

OpenAI, Anthropic, Google 등 다양한 Provider에서는 새로운 AI 모델을 계속 출시한다.

로그베이스가 새 모델을 활용할 때마다 개발자가 모델 ID, API 설정, 가격정보를 소스코드에 직접 추가하는 방식은 운영 부담을 증가시킨다.

AI 모델 관리는 관리자가 OpenRouter에서 제공하는 모델을 검색·등록·검증하고, Patron에서 사용할 수 있는 상태로 관리하는 기능이다.

중요한 점은 모델 등록이 운영 서비스의 모델 변경을 의미하지 않는다는 것이다.

이번 PoC에서 활성화한 모델은 Patron 시뮬레이터 등 PoC 기능에서 사용할 수 있으며, 실제 AI PDP 운영 모델은 자동으로 변경되지 않는다.

2. 주요 기능

번호	화면 영역	제공 기능
①	모델 검색	모델명·Model ID·Provider·상태별 검색
②	모델 목록	등록된 모델의 주요 정보 조회
③	신규 모델 등록	OpenRouter 지원 모델 등록
④	모델 상세	모델 정보·가격·지원 기능 확인
⑤	연결 테스트	실제 API 호출을 통해 사용 가능 여부 검증
⑥	상태 관리	TESTING·ACTIVE·INACTIVE 변경

3. 기능별 상세 설명

① 모델 검색

관리자는 등록된 모델을 이름, Model ID, Provider, 상태를 기준으로 검색한다.

Model ID는 실제 API 호출에 사용되는 식별자이고, 표시 이름은 관리자가 알아보기 쉽도록 제공하는 이름이다.

두 값은 서로 다를 수 있으므로 구분해 관리한다.

② 모델 목록

모델 목록에는 다음 정보를 제공한다.

- 표시 이름
- Model ID
- Provider
- 지원 기능
- Input Token 가격
- Output Token 가격
- 현재 상태
- 마지막 연결 테스트 일시
- 연결 테스트 실행

모든 데이터 컬럼은 정렬 가능해야 한다. 모델명을 클릭하면 상세정보로 이동하고, 목록의 테스트 버튼을 누르면 연결 테스트를 수행할 수 있어야 한다. 목록이 일부만 표시되면 전체보기 또는 페이지네이션으로 나머지 모델을 조회한다.

③ 신규 모델 등록

모델 등록 절차는 다음과 같다.

1. OpenRouter에서 제공하는 모델 목록을 조회한다.
2. 등록할 Model ID를 선택한다.
3. Provider·모델명·지원 기능·가격정보를 확인한다.
4. 기존 Patron 등록 모델과 중복되는지 검사한다.
5. 신규 모델을 TESTING 상태로 등록한다.

이미 등록된 동일 Model ID는 중복 등록하지 않는다. OpenRouter에서 제공하지 않는 새 Provider를 UI만으로 자동 연동하는 기능은 이번 PoC 범위에 포함하지 않는다.

④ 모델 상세정보

관리자는 등록 모델의 상세정보를 조회하고 수정할 수 있다.

주요 정보:

- 모델 ID 및 표시 이름
- Provider
- 텍스트·이미지 등 지원 기능
- Context Length 등 제공 가능한 모델 정보
- Input/Output Token 단가
- 가격 확인 시각
- 모델 상태
- 마지막 테스트 결과 및 시각

가격은 반드시 Input과 Output을 구분한다. 모델 가격이 변경되어도 이전에 발생한 API 호출의 확정 비용을 현재 가격으로 자동 재계산하지 않는다. 가격 단위와 기준 시각은 실제 Provider 정보에 맞춰 저장해야 한다.

⑤ 연결 테스트

모델을 등록한 후 관리자에게 실제로 호출할 수 있는지 확인하는 기능을 제공한다.

처리 절차:

1. 테스트할 모델 선택
2. 테스트 Prompt 지정
3. PoC 전용 Credential로 호출
4. 성공 또는 실패 결과 확인
5. 응답시간·Token·비용 확인
6. 마지막 테스트 결과와 시각 저장

연결 테스트에 성공했다는 것은 해당 시점에 API 호출이 성공했다는 의미다. 이후에도 항상 성공한다는 보장은 아니다. 연결 테스트도 실제 AI API 호출이므로 비용이 발생할 수 있으며, 해당 이력은 SYSTEM_TEST로 구분한다.

⑥ 모델 상태 관리

세 가지 상태를 사용한다.

상태	의미	사용 정책
TESTING	등록 후 검증 단계	관리자 연결 테스트 가능
ACTIVE	검증 후 사용 승인	일반 시뮬레이터에서 선택 가능
INACTIVE	사용 중단	신규 시뮬레이터 실행에서 제외

신규 등록 모델은 TESTING 상태로 시작한다. 연결 테스트가 성공한 뒤에도 관리자가 명시적으로 ACTIVE로 전환해야 한다. 연결 테스트 실패 모델은 ACTIVE로 전환할 수 없도록 한다.

이미 ACTIVE였던 모델에서 이후 테스트가 실패하는 경우 실패 상태와 시각을 기록한다. 자동 비활성화 여부는 별도 운영정책으로 다루며 이번 PoC에서 자동 전환을 강제하지 않는다.

모델이 비활성화되어도 과거 사용 이력과 시뮬레이션 결과는 유지한다.

4. 데이터 수집 및 처리

OpenRouter 모델 목록과 Patron 모델 등록정보는 구분해서 관리한다.

- OpenRouter: 외부에서 제공하는 모델·가격·지원 기능 정보
- Patron: 실제 등록 여부, 표시 이름, 상태, 테스트 결과 등 내부 운영 정보

처리 흐름:

1. 외부 모델 목록 조회
2. 등록 모델 선택
3. Patron 모델 레지스트리에 저장
4. 연결 테스트 수행
5. 관리자 ACTIVE 전환
6. Simulator 선택 목록에 반영

OpenRouter 모델 목록이 변경되어도 Patron에서 모델을 자동 활성화하지 않는다.

5. 공통 화면 동작 및 예외 처리

- 모든 데이터 컬럼 Sorting 지원
- 모델명 클릭 시 상세 조회
- 모델 연결 테스트 버튼 제공
- 목록 일부 표시 시 전체보기
- 중복 모델 등록 차단
- 인증 실패·Rate Limit·Timeout 등 오류 표시
- 가격정보 미확인 상태 구분
- 테스트 성공과 모델 ACTIVE 상태 구분
- INACTIVE 모델의 과거 기록 보존

6. PoC 구현 범위

필수 구현

- OpenRouter 모델 목록 조회
- 모델 검색·등록·수정
- 중복 등록 방지
- 지원 기능 및 가격정보 확인
- 연결 테스트
- TESTING·ACTIVE·INACTIVE 관리
- 마지막 테스트 결과·시각 기록
- ACTIVE 모델과 Simulator 연결

후속 확장

- 모델 가격 자동 변경 알림
- 신규 Provider의 무코드 API 연동
- 모델 자동 성능 평가
- 서비스별 모델 자동 배포·교체

7. 완료조건 (Definition of Done)

1. OpenRouter에서 제공하는 모델을 조회할 수 있다.
2. 신규 모델을 등록하면 TESTING 상태로 저장된다.
3. 같은 Model ID의 중복 등록을 차단한다.
4. 연결 테스트 결과와 실행 시각을 기록한다.
5. 테스트 성공 모델을 관리자가 ACTIVE로 변경할 수 있다.
6. ACTIVE 모델은 시뮬레이터에서 선택 가능하다.
7. INACTIVE 모델은 신규 실행 대상에서 제외된다.
8. 모델 비활성화 이후에도 과거 이력은 보존된다.
9. Input/Output 가격과 가격 기준정보를 구분한다.

최종 시연 예시

OpenRouter 모델 검색 → 신규 모델 등록 → TESTING 확인 → 연결 테스트 → ACTIVE 변경 → Simulator에서 등록 모델 선택 확인

P-04. AI 모델 시뮬레이터

상세 기능 설명서 v1.0

1. 화면의 목적

AI 모델은 같은 Prompt를 받아도 서로 다른 답변을 생성하며, 응답시간·Token 사용량·비용도 달라질 수 있다.

어떤 모델이 특정 업무에 적합한지 판단하려면 동일한 입력으로 여러 모델을 실행하고 실제 결과를 비교할 필요가 있다.

Multi-LLM Simulator는 동일한 작업을 여러 AI 모델에 병렬 실행하여 응답 내용, 속도, Token, 비용 및 출력 형식 준수 여부를 비교하는 기능이다.

예를 들어 상품 설명을 생성하는 업무에 세 가지 모델을 실행하여 어느 모델이 더 빠르고 저렴하며 요구한 출력 형식을 잘 지키는지 확인할 수 있다.

단, 이번 PoC에서는 모델의 내용 품질을 자동 채점하거나 최적 모델을 자동 선정하지 않는다.

2. 주요 기능

번호	화면 영역	제공 기능
①	테스트 유형	미리 정의된 시나리오 또는 Custom Prompt 선택
②	테스트 입력	Prompt·텍스트·이미지 등 입력
③	모델 선택	등록된 ACTIVE 모델 2~4개 선택
④	비교 실행	동일 입력을 병렬 전달
⑤	실행 결과 요약	성공·실패 수, 확정·추정 비용, 미확인 건수
⑥	모델별 결과	응답시간·Token·비용·출력 검증 비교
⑦	응답 상세	전체 응답 내용 확인
⑧	실행 이력	실행 조건 및 모델별 결과 저장

3. 기능별 상세 설명

① 테스트 유형

관리자는 테스트 목적에 따라 시나리오를 선택한다.

기본 테스트 유형은 다음과 같다.

- 상품 이미지 및 속성 분석
- 상품 설명과 마케팅 문구 생성
- 데이터 요약·구조화
- 비정형 텍스트의 JSON 변환
- 일반 분석 및 추론

Custom Prompt를 선택하면 직접 작성한 Prompt를 실행한다.

시나리오는 단순한 화면 제목이 아니라 테스트 목적에 맞는 입력 형식과 출력 조건을 정의한 템플릿이다.

② 테스트 입력

사용자는 Prompt와 필요한 입력 데이터를 입력한다.

Prompt는 AI 모델에 전달할 작업 지시문이다.

입력 데이터는 상품 정보, 문장, JSON, 이미지 등 작업을 수행하기 위한 자료다.

이미지를 입력하는 경우 선택한 모델이 이미지 입력을 지원하는지 사전에 확인한다.

이미지 미지원 모델은 실행 전 미지원 안내를 제공해야 한다.

실제 이미지 기반 병렬 실행 범위는 1주차 OpenRouter API 검증 결과에 따라 확정한다.

③ 모델 선택

관리자는 비교할 모델을 최소 2개, 최대 4개 선택한다.

일반 시뮬레이터에서는 P-03에서 ACTIVE로 등록된 모델만 선택할 수 있다.

5개 이상 선택하거나 1개 모델만 선택한 상태에서는 비교 실행을 허용하지 않는다.

모델 ID가 같더라도 실행 Provider나 설정에 차이가 발생할 수 있으므로 실행 조건을 기록한다.

④ 비교 실행

실행 버튼을 누르면 다음 작업을 수행한다.

1. 입력 데이터와 선택 모델을 검증한다.
2. 실행 조건과 입력정보를 확정한다.
3. 하나의 Simulation ID를 생성한다.
4. 모델별 고유 Request ID를 생성한다.
5. OpenRouter를 통해 모델을 병렬 호출한다.
6. 응답·Token·비용·처리시간을 수집한다.
7. 모델별 검증 결과를 저장한다.
8. 전체 시뮬레이션 상태를 결정한다.

실행 시작 시점과 완료 시점을 기록한다.

여러 모델을 병렬 실행하므로 전체 실행시간은 개별 모델 실행시간의 단순 합계가 아니다.

⑤ 실행 결과 요약

전체 실행의 핵심 정보를 요약한다.

- 실행한 모델 수
- 성공 모델 수
- 실패·Timeout 모델 수
- 전체 실행 상태
- 확정 비용
- 추정 비용
- 비용 미확인 건수

전체 실행 상태는 개별 모델 실행 상태와 다르다.

예를 들어 3개 모델 중 2개가 성공하고 1개가 Timeout되면 전체 상태는 PARTIAL_SUCCESS(부분 성공)로 처리한다.

모두 성공하면 SUCCESS, 성공 모델 없이 모두 실패하면 FAILED로 처리한다.

실행이 아직 진행 중이면 RUNNING 상태를 표시한다.

⑥ 모델별 실행 결과

각 모델의 실행 결과를 동일한 기준으로 비교한다.

지표	의미
실행 상태	성공·실패·Timeout 등
응답시간	개별 모델 응답 소요시간

Input Token	모델에 전달된 입력 Token
Output Token	모델이 생성한 출력 Token
비용	확정·추정·미확인 비용
JSON 검증	JSON 파싱 성공 여부
Schema 검증	지정 Schema 준수 여부

JSON 검증과 Schema 검증은 구분해야 한다.

JSON 파싱에 성공했다고 반드시 지정한 Schema를 준수한 것은 아니다.

Schema를 지정하지 않은 테스트는 검증 결과를 '미적용'으로 표시한다.

응답 자체를 받지 못한 모델은 Schema 검증을 실행하지 않았으므로 '검증 실패'가 아닌 '미실행'으로 처리한다.

⑦ 전체 응답 보기

모델별 응답은 길어질 수 있으므로 요약을 먼저 보여주고 '전체 응답 보기'로 원문을 확인한다.

이때 응답 내용은 변경하지 않고 보존한다.

결과를 비교할 때에는 동일한 입력으로 생성한 응답이라는 사실과 사용된 실행 조건을 확인할 수 있어야 한다.

⑧ 실행 이력 저장

시뮬레이션의 실행 조건과 결과를 저장한다.

주요 저장 정보는 다음과 같다.

- Simulation ID
- Prompt 및 입력 데이터 참조
- 선택한 모델
- 실행 파라미터
- Provider 및 Fallback 설정
- 모델별 응답 결과
- Token·비용·처리시간
- 실행 상태 및 검증 결과

실행 기록은 P-05 시뮬레이션 결과 이력에서 재조회한다.

4. 비교 공정성 및 데이터 처리

동일 Prompt를 사용하는 것만으로 완전히 동일한 비교 조건이 성립하지는 않는다.

OpenRouter는 동일 모델에 대해 여러 실행 Provider를 사용할 수 있으므로 비교할 때 가능한 범위에서 Provider를 고정하고 Fallback을 비활성화한다.

모델별로 지원 파라미터가 다를 수 있어 완전히 동일한 조건을 적용하기 어려운 경우에는 차이를 기록한다.

또한 모델의 한 번의 응답으로 품질 순위를 확정하지 않는다.

Simulator 호출에는 `SIMULATION` 출처를 지정하고 고객 AI 사용량과 분리한다.

특정 모델이 실패하더라도 다른 모델의 결과는 정상적으로 저장되어야 한다.

5. 공통 화면 동작 및 예외 처리

- 모델 2~4개 선택 제한
- ACTIVE 모델만 일반 실행 가능
- 이미지 미지원 모델 사전 안내
- 고급 설정은 필요 시 펼침
- 모델별 결과 정렬 및 상세 응답 보기
- 개별 모델 오류와 전체 상태 분리
- 실패·Timeout 비용을 임의로 0원 처리하지 않음
- 실행 중 서버 오류 발생 시 미완료 이력 복구 또는 종료 판정
- 실행 이력에서 결과 재조회

6. PoC 구현 범위

필수 구현

- 테스트 시나리오 및 Custom Prompt
- 모델 2~4개 선택
- 병렬 API 호출
- 결과·Token·비용·시간 측정
- 개별 실행 실패 격리
- 전체 실행 상태
- JSON·Schema 검증
- 전체 응답 보기

- 결과 및 실행 조건 저장

후속 확장

- AI 품질 자동 채점
- 최적 모델 자동 추천
- 모델 자동 라우팅
- 대규모 반복 Benchmark
- AI PDP 운영환경 모델 자동 교체

7. 완료조건 (Definition of Done)

1. 최소 2개, 최대 4개 모델을 선택해 실행할 수 있다.
2. 3개 Provider 계열의 모델로 비교 테스트를 수행할 수 있다.
3. 동일한 입력을 각 모델에 병렬 전달한다.
4. 모델별 응답시간·Token·비용을 조회한다.
5. 하나의 모델이 실패해도 다른 모델 결과를 보존한다.
6. Timeout 발생 시 비용 미확인을 구분한다.
7. JSON·Schema 검증 결과를 구분해 표시한다.
8. 전체 실행 상태가 모델별 종료 결과와 일치한다.
9. 실행 조건과 결과가 이력으로 저장된다.
10. 입력 미지원 모델을 사전에 안내한다.

최종 시연 예시

마케팅 문구 생성 선택 → Prompt 입력 → 3개 모델 선택 → 비교 실행 → 응답·시간·비용 비교 → 모델 1개 Timeout 시 부분 성공 확인 → 실행 결과 이력 저장

P-05. 시뮬레이션 결과 이력

상세 기능 설명서 v1.0

1. 화면의 목적

모델 시뮬레이션은 한 번의 비교로 끝나는 기능이 아니다.

같은 Prompt를 사용하더라도 모델 버전, 실행 조건, Provider 설정, 실행 시점 등에 따라 결과가 달라질 수 있다.

따라서 과거의 실행 결과를 보존하고 새로운 결과와 비교할 수 있어야 한다.

시뮬레이션 결과 이력은 P-04에서 수행한 모델 비교 기록을 조회하고, 당시 실행 조건을 확인하며, 필요한 경우 동일한 입력으로 다시 테스트할 수 있도록 하는 기능이다.

이 화면은 과거 실행을 검색·조회하는 것이 주목적이며, 새로운 모델 비교 실행은 P-04에서 수행한다.

2. 주요 기능

번호	화면 영역	제공 기능
①	검색 조건	기간·시나리오·모델·상태별 조회
②	실행 이력 목록	과거 시뮬레이션 결과 조회
③	실행 상태	전체 성공·부분 성공·실패·진행 중 확인
④	비용 상태	확정·추정 포함·미확인 포함 구분
⑤	실행 상세	과거 입력·모델·응답·실행 조건 확인
⑥	재실행	이전 입력과 모델 설정으로 새로운 시뮬레이션 시작

3. 기능별 상세 설명

① 검색 조건

관리자는 과거 실행을 다음 조건으로 조회한다.

- 실행 기간

- 테스트 시나리오
- 실행 모델
- 실행 상태
- Simulation ID

조건을 입력하고 조회하면 해당하는 시뮬레이션 이력만 표시한다.

최신 실행을 기본으로 보여주되 모든 데이터 컬럼에서 Sorting이 가능해야 한다.

② 시뮬레이션 이력 목록

각 행은 하나의 Simulation 실행을 의미한다.

하나의 Simulation에는 2~4개의 모델별 실행 결과가 포함될 수 있다.

주요 목록 정보는 다음과 같다.

- 실행 시각
- Simulation ID
- 테스트 시나리오
- 참여 모델 수
- 전체 실행 상태
- 비용 확인 상태
- 총 비용

예를 들어 모델 3개를 비교했다면 이력 목록에는 Simulation 1건이 표시되고, 그 아래에 모델별 Request 3건이 연결된다.

Simulation ID를 클릭하면 해당 실행의 상세정보로 이동한다.

모델별 API 호출 이력과 전체 Simulation 이력을 혼동하지 않아야 한다.

③ 실행 상태

전체 실행 상태는 P-04에서 결정된 값을 그대로 사용한다.

상태	의미
PENDING	실행 등록 후 대기
RUNNING	하나 이상의 모델이 실행 중
SUCCESS	모든 모델 정상 완료

PARTIAL_SUCCESS	일부 모델 성공, 일부 실패·Timeout 등
FAILED	성공한 모델 없이 실패 종료
CANCELLED	취소로 종료

P-05에서 실행 상태를 임의로 다시 판단하거나 변경하지 않는다.

저장된 실제 실행 상태를 그대로 조회한다.

④ 비용 확인 상태

전체 실행 비용도 모델별 호출 비용을 기준으로 집계한다.

- 확정: 포함된 모든 호출 비용이 확정된 경우
- 추정 포함: 하나 이상의 호출에 추정 비용이 포함된 경우
- 미확인 포함: 하나 이상의 호출 비용을 확인할 수 없는 경우
- 확인 중: 실행이 끝나지 않았거나 비용 조회·대조가 진행 중인 경우

확정 비용과 추정 비용은 합산 참고금액으로 표시할 수 있지만, 반드시 '추정 포함'을 명시해야 한다.

비용 미확인 호출이 있다면 표시된 합계는 전체 최종 비용이 아닐 수 있다.

실패한 실행의 비용을 자동으로 0 USD로 처리하지 않는다.

⑤ 실행 상세정보

관리자가 Simulation ID를 선택하면 당시 실행 정보를 확인한다.

주요 정보:

- 실행 시각
- Prompt 및 입력 참조
- 테스트 시나리오
- 선택 모델
- 실제 응답 Provider
- 실행 파라미터
- Fallback 정책
- 모델별 실행 상태
- Token·비용·응답시간
- 원본 응답
- JSON·Schema 검증 결과

과거 실행에 사용된 모델이 현재 INACTIVE 상태여도 저장된 결과는 그대로 확인할 수 있어야 한다.

과거 실행 이력을 현재의 모델 가격이나 설정으로 덮어쓰면 안 된다.

⑥ 재실행

관리자는 과거 입력과 설정을 활용해 다시 시뮬레이션을 시작한다.

처리 흐름:

1. 과거 Simulation 상세 조회
2. 재실행 선택
3. 과거 Prompt·입력·모델·설정 복원
4. 현재 등록 모델 상태 확인
5. 비활성 모델의 교체 또는 제외 안내
6. 필요한 설정 변경
7. 새로운 Simulation ID 생성
8. P-04에서 신규 비교 실행

기존 Simulation ID와 결과는 변경하지 않는다.

비활성 모델을 제외한 결과 비교 대상이 2개 미만이라면 추가 모델을 선택하도록 안내한다.

입력 데이터가 삭제되었거나 접근할 수 없다면 재실행을 제한하고 사유를 표시한다.

4. 데이터 수집 및 처리

P-05는 외부 AI API를 직접 조회해서 과거 결과를 재구성하는 화면이 아니다.

Patron에 저장된 SimulationRun과 모델별 호출 이력을 조회하는 화면이다.

처리 절차:

1. P-04에서 Simulation ID 생성
2. 모델별 Request ID 및 실행 정보 저장
3. 개별 결과·Token·비용 기록
4. 전체 실행 상태 확정
5. P-05에서 실행 이력 검색·조회
6. 필요 시 입력값을 복원하여 새로운 Simulation 시작

이미 저장된 이력을 조회하는 행동에는 새로운 AI API 호출 비용이 발생하지 않는다.

단, 재실행하면 새로운 API 호출이 발생하므로 별도의 비용이 발생할 수 있다.

5. 공통 화면 동작 및 예외 처리

- 모든 데이터 컬럼 Sorting 지원
- 전체 결과 대상 정렬 후 페이지네이션
- Simulation ID 클릭 시 상세 조회
- 실행 상태와 비용 상태 분리
- 현재 모델 상태와 과거 실행 결과 분리
- 비활성 모델의 과거 기록 보존
- 재실행 시 현재 모델 상태 재검증
- 실행 중 이력은 결과 미완료 상태로 표시
- 저장된 Prompt 또는 입력이 없으면 재실행 불가 안내
- 기존 기록 덮어쓰기 금지

6. PoC 구현 범위

필수 구현

- 기간·시나리오·모델·상태 검색
- 실행 이력 목록
- Sorting 및 페이지네이션
- Simulation ID 기반 상세 조회
- 과거 Prompt·모델·실행 조건 조회
- 모델별 응답 및 비용 조회
- 과거 입력으로 재실행
- 비활성 모델 재실행 제한
- 신규 실행 이력 생성

후속 확장

- 두 실행 결과 간 자동 차이 분석
- 모델 버전별 성능 추이 분석
- 반복 실행 Benchmark 보고서
- 자동 회귀 테스트
- 품질 점수 기반 모델 추천

7. 완료조건 (Definition of Done)

1. 과거 Simulation 실행 이력을 검색할 수 있다.

2. 최신 실행과 과거 실행을 정확히 구분한다.
3. 목록의 모든 데이터 컬럼에서 정렬할 수 있다.
4. Simulation ID로 상세정보를 조회한다.
5. 모델별 응답·비용·실행 설정을 확인한다.
6. 비활성 모델의 과거 결과를 보존한다.
7. 재실행 시 기존 결과를 수정하지 않는다.
8. 신규 Simulation ID를 생성한다.
9. 비활성 모델이 포함된 경우 교체·제외를 안내한다.
10. 실행 상태와 비용 확인 상태를 별도로 표시한다.

최종 시연 예시

과거 Simulation 검색 → 실행 결과 확인 → 모델별 응답 및 비용 비교 → 비활성 모델 확인 → 모델 교체 → 재실행 → 신규 Simulation ID 생성 확인